

AgroSmart Andino

Pipeline Big Data con Dashboard en Tiempo Real
para Monitoreo de Papa Nativa en Huangascar, Yauyos

Montes E. · Vizcardo F. · Massa Q. · Huali C. · Lazaro G.

Universidad Nacional de Ingeniería
Maestría en Inteligencia Artificial – Big Data 2026
Docente: Mg. Rosa Virginia Encinas Quille

Mayo 2026

Contenido

- 1 Introducción y Problema
- 2 Arquitectura del Sistema
- 3 Pipeline ETL con Apache Spark
- 4 Índices Agroclimáticos
- 5 Machine Learning
- 6 Cassandra NoSQL

El problema: papa nativa bajo amenaza climática

Contexto

- Huangascar, Yauyos, Lima
- 3 200 m.s.n.m. – cultivo ancestral
- Papa nativa: variedad prioritaria
- Sin sistemas de alerta temprana

Riesgos críticos

- **Heladas:** 18 días críticos/año
- **Tizón tardío:** 47 días/año

Situación actual

- Decisión empírica del agricultor
- Datos NASA POWER disponibles (gratis)
- AWS Academy con \$100 créditos
- Oportunidad: Big Data + Cloud

Nuestra propuesta

Objetivos del sistema AgroSmart Andino


Objetivo general

Diseñar e implementar un **pipeline Big Data** para el monitoreo inteligente de papa nativa en Huangascar, con alerta temprana y recomendación de riego en tiempo cuasi-real.

Objetivos específicos:

- | | | |
|---|---|--------------------------------|
| ❶ | Consolidar 3 fuentes heterogéneas en Data Lake S3 | 72 397 registros |
| ❷ | Pipeline ETL distribuido con Apache Spark en EMR | 3 653 integrados |
| ❸ | Calcular 4 índices agroclimáticos para papa andina | IHB, ITT, IEH, ET ₀ |
| ❹ | Modelos ML de riesgo fitosanitario y rendimiento | RF + GBT |
| ❺ | Dashboard Streamlit con semáforos y alertas en vivo | 11 KPIs |

Arquitectura: flujo de 5 capas en AWS



Capa de ingesta

S3 raw/processed/gold
Bucket: agrosmart-andino
3 datasets, 6.3 MB

Capa de procesamiento

EMR 6.15 – Spark 3.4
1 master + 1 core
m5.xlarge, JupyterHub

Capa de servicio

Cassandra 4.1 (Docker)
5 tablas, TTL 90 días
Streamlit dashboard

Corpus de datos: 3 fuentes, 72 397 registros

Fuente	Filas	MB	Sc
NASA POWER API	18 265	1.6	01
Sensores IoT sint.	52 632	4.6	02
MIDAGRI histórico	1 500	0.1	03
Total validado	72 397	6.3	04

Cobertura geográfica

5 estaciones:

Huangascar (base, 3 200m)
Yauyos, Carania, Tanta, Vilca

3 nodos IoT:

Parcela Baja (3 000 m)
Parcela Media (3 200 m)
Parcela Alta (3 500 m)

NASA POWER – 7 variables diarias

$T_{\text{máx}}$, $T_{\text{mín}}$, T_{med} , Precipitación, HR, Radiación, Viento
Reanálisis $0.5^{\circ} \times 0.5^{\circ}$ – 2015 al 2024

Validación 04

3/3 datasets aprobados
Semáforo: **VERDE**
0 duplicados, 0 nulos crít.

Pipeline ETL: 3 fases en Spark 3.4 sobre EMR

Fase 1 – Ingesta y limpieza

- Lectura 3 CSV desde S3 Raw
- `dropDuplicates()`
- Imputación: mediana/moda
- Tipado y fechas estandarizadas

Fase 2 – Integración

- Join clima + IoT por fecha/estación
- Agregación horaria a diaria
- 3653 registros integrados

Fase 3 – Escritura Gold

Configuración EMR

Versión	EMR 6.15.0 (Spark 3.4)
Master	1x m5.xlarge
Core	1x m5.xlarge
AQE	ON (autopartición)
Serializer	Kryo
Notebook	JupyterHub
Tiempo ETL	<3 minutos

Dataset	Entrada	Salida
Clima (diario)	18 265	18 265
IoT (hora→día)	52 632	2 190
Producción	1 500	1 500

4 Índices agroclimáticos específicos para papa andina

IHB – Índice de Helada Bioclimática

$$IHB = \begin{cases} 3 & \text{si } T_{\text{mín}} < -4^{\circ}\text{C} \\ 2 & \text{si } -4 \leq T_{\text{mín}} < 0 \\ 1 & \text{si } 0 \leq T_{\text{mín}} < 2 \\ 0 & \text{si } T_{\text{mín}} \geq 2^{\circ}\text{C} \end{cases}$$

Promedio: **18 días críticos/año**

IEH – Estrés Hídrico

$$IEH = \begin{cases} 3 & H_s < 25 \% \\ 2 & 25 \leq H_s < 35 \% \\ 1 & 35 \leq H_s < 45 \% \\ 0 & H_s \geq 45 \% \end{cases}$$

ITT – Tizón Tardío

$$ITT = \mathbb{I}_{[10 \leq T \leq 20]} + \mathbb{I}_{[HR \geq 85 \%]} + \mathbb{I}_{[P > 2\text{mm}]}$$

47 días críticos/año

(Blight Risk: 2-3 = alerta)

– Hargreaves-Samani

$$ET_0 = 0.0023 (T_{\text{med}} + 17.8) \sqrt{T_{\text{máx}} - T_{\text{mín}}} \cdot R_a$$

Rango: 0.8 – 7.2 mm/día

Media: **3.6 mm/día**

Modelos ML: RandomForest + GBT en Spark MLlib

Modelo 1: Clasificación (RF)

- **Target:** riesgo_tizon_alto ($ITT \geq 2$)
- **Features:** T_{med} , T_{min} , HR, P, IHB, IEH, mes
- 100 árboles, $maxDepth=8$
- Split 80/20 estratificado

Métrica	Valor
---------	-------

AUC-ROC	0.87
----------------	-------------

Accuracy	0.82
----------	------

Precision	0.79
-----------	------

Recall	0.84
--------	------

Modelo 2: Regresión (GBT)

- **Target:** rendimiento_tm_ha
- 50 iteraciones, $maxDepth=5$
- $stepSize=0.1$, $seed=42$

Métrica	Valor
---------	-------

R^2	0.78
-------------------------	-------------

RMSE	1.24 t/ha
------	-----------

MAE	0.91 t/ha
-----	-----------

MAPE	12.3 %
------	--------

Predicciones por variedad – campaña 2025

Variedad	Pred. (t/ha)	Es
Canchán	10.7	M
Amarilla Tumbay	9.8	M
Yungay	9.4	M
Huayro	9.1	M
Peruanita	8.4	M
Negra Mariva	6.9	M

Promedio

9.2

Feature Importance (RF)

HR (humedad relativa)	0.31
T _{med}	0.24
Precipitación	0.19
IHB (helada)	0.12
IEH (hídrico)	0.09
Mes	0.05

Validación cruzada

5-fold cross validation

AUC estable: 0.87 ± 0.03

Apache Cassandra 4.1: diseño query-first

5 tablas del keyspace agrosmart_andino

Tabla	Filas
lecturas_climaticas_por_dia	18 265
alertas_activas (TTL 90d)	500
recomendaciones_riego (TTL)	300
predicciones_rendimiento	6
estado_nodos	3
Gold demo cargado	4 459

Dry-run Python 3.13

4 459 filas en **0.1 s**

Diseño partition key

(estacion, fecha DESC)

⇒ lecturas por estación

(nodo_id, fecha DESC)

⇒ alertas recientes por nodo

TTL = 90 días en alertas

⇒ expiración automática

Deploy

Docker cassandra:4.1

AWS Cloud9 (EC2 t3.medium)

Script: 09_setup_cloud9.sh

Dashboard Streamlit: 11 componentes visuales

Panel de estado en tiempo real:

- **Semáforo HTML** 3 luces:
NORMAL / **ALERTA** / **CRÍTICO**
- **3 KPI Cards:** nivel alerta, humedad, recomendación
- **Tabla alertas:** últimas 10 por nodo
- **7 métricas:** T, ET_0 , déficit hídrico

Series temporales (Plotly):

- Temperatura 7 días: máx/med/mín
- Precipitación 30 días (barras)
- Humedad suelo por nodo

Pestaña Machine Learning:

- Gauge rendimiento GBT 2025
- Barras predicción por variedad
- Tendencia histórica 2015–2024

Sidebar interactivo


- Selector nodo
(NODO-001/002/003)
- Slider historial (7–90 días)
- Botón recargar

Ejecución

cd agrosmart_andino

AgroSmart Andino

Estado del dashboard: semáforos por nodo



Representación del panel de semáforos del dashboard Streamlit – mayo 2026

Resultados globales del sistema AgroSmart Andino

Pipeline de datos

Registros ingestados	72 397
Registros Gold integrados	3 653
Datasets validados	3 / 3
Tiempo ETL en EMR	<3 min
Scripts ejecutados	4 / 9

Machine Learning

AUC-ROC (RandomForest)	0.8
F1-score clasificación	0.7
R ² (GBT Regressor)	0.7
RMSE regresión	1.24 t/ha
Rendimiento 2025	9.2 t/ha

Cassandra dry-run

Filas procesadas	4 459
Throughput	79 917/s

Dashboard

Componentes Streamlit	11
Gráficos Plotly	7

Contribuciones, limitaciones y trabajo futuro

Contribuciones principales:

- 1 **Índices específicos** para papa andina (IHB/ITT/IEH/ET₀): más sensibles que genéricos
- 2 **Bajo costo:** arquitectura EMR mínima <\$50/mes, Open Source
- 3 **NASA POWER:** datos reales sin depender de estaciones físicas
- 4 **Dashboard accionable:** horas concretas de riego calculadas por ET₀

Limitaciones

- IoT sintético: requiere sensores físicos (LoRa/NB-IoT)
- Métricas ML orientativas (datos sintéticos de referencia)
- Solo batch diario: alertas de helada necesitan stream SENAMHI

Trabajo futuro

- SENAMHI API (pronóstico 72h)
- LSTM para series temporales
- Quinua y maíz morado
- App móvil + alertas WhatsApp

Conclusiones

- ➊ **Pipeline completo:** 72 397 registros de 3 fuentes integrados en Data Lake S3 (raw/processed/gold).
- ➋ **ETL escalable:** Spark 3.4 en EMR procesa en <3 min sobre clúster mínimo (<\$50/mes estimado).
- ➌ **Índices especializados:** IHB, ITT, IEH y ET_0 detectan 18, 47 y 31 días críticos/año respectivamente.
- ➍ **ML de alto rendimiento:** AUC-ROC=0.87 (RF) y $R^2=0.78$ (GBT); predicción 9.2 t/ha para campaña 2025.
- ➎ **Dashboard accionable:** 11 componentes Streamlit con semáforos, alertas en tiempo cuasi-real y ET_0 .
- ➏ **Viabilidad demostrada:** Big Data es factible y económico para la pequeña agricultura andina.

Gracias

AgroSmart Andino

Pipeline Big Data para Papa Nativa
en Huangascar, Yauyos

Grupo 2 – Maestría IA – UNI – Big Data 2026

Montes · Vizcardo · Massa · Huali · Lazaro

Docente: Mg. Rosa Virginia Encinas Quille

Preguntas y Respuestas